

1. 本部分在项目中的作用

本项目的核心目标不是单纯介绍连续时间量子游走，而是验证一种明确的算法假设：


连续时间量子游走产生的节点概率分布，能够比传统局部指标更好地反映图的全局拓扑结构，并可作为贪心算法的节点评分依据，从而提升图组合优化问题的求解质量。

因此，本部分的任务是为后续实验提供理论基础和算法定义，包括：

- 明确要优化的图组合问题；
- 定义量子引导贪心算法的数学形式；
- 给出可实现的评分函数；
- 明确实验中需要对比的基准方法；
- 提出可以被实验验证或否定的研究假设；
- 为后续消融实验、参数实验和性能分析提供依据。

项目整体采用“量子全局视野 + 经典局部贪心”的双层架构。连续时间量子游走负责生成包含全局拓扑信息的节点概率分布，经典贪心策略负责在候选集合中完成节点选择。这样既保留了量子游走对图结构的全局感知能力，又保证最终输出结果满足具体图优化问题的约束。

量子全局视野 + 经典局部贪心的双层架构



图中可以看出，量子部分并不直接替代组合优化算法本身，而是作为一个全局评分器嵌入每一轮贪心选择。经典部分仍负责处理可行性约束、停止条件和最终解的合法性。因此，本项目的理论重点在于说明：CTQW 生成的概率分布为什么能够作为有意义的全局结构信号，以及这种信号如何与经典局部评分结合。

2. 研究对象与问题建模

本项目面向图组合优化问题，重点考虑两类具有代表性的任务：最大团问题和密集子图发现问题。

设无向图为：

$$G = (V, E)$$

其中， V 表示节点集合， E 表示边集合。图的邻接矩阵记为 A ，若节点 i 与节点 j 之间存在边，则：

$$A_{ij} = 1$$

否则：

$$A_{ij} = 0$$

2.1 最大团问题

最大团问题要求在图中寻找一个尽可能大的节点集合 $S \subseteq V$ ，使得集合中任意两个不同节点之间都存在边。即：

$$\forall u, v \in S, u \neq v, (u, v) \in E$$

该问题可以写成：

$$\max |S|$$

约束条件为：

$$\forall u, v \in S, u \neq v, (u, v) \in E$$

最大团问题是经典 NP-Hard 图组合优化问题。当图规模较大时，精确搜索方法的计算代价会迅速增加，因此实际应用中通常需要借助启发式算法或近似算法。

对于本项目而言，最大团问题适合作为第一类实验对象，原因在于它的约束明确，结果容易判断。如果算法输出的节点集合中任意两点均相连，则该集合就是一个合法团。因此，最大团问题可以用于验证量子引导贪心算法是否能够在强约束条件下找到更大的高质量节点集合。

2.2 密集子图发现问题

密集子图发现问题不要求节点之间两两相连，而是希望找到内部连接尽可能紧密的节点集合。设 S 内部边集为 $E(S)$ ，则子图密度定义为：

$$\rho(S) = \frac{2|E(S)|}{|S|(|S|-1)}$$

其中：

- $|S|$ 为子图节点数；
- $|E(S)|$ 为子图内部边数；
- $\rho(S) \in [0, 1]$ 。

该公式来自无向简单图的最大可能边数。若 $|S|$ 个节点两两相连，则内部边数最多为：

$$\binom{|S|}{2} = \frac{|S|(|S|-1)}{2}$$

因此密度可以写成：

$$\rho(S) = \frac{|E(S)|}{\binom{|S|}{2}} = \frac{2|E(S)|}{|S|(|S|-1)}$$

所以 $\rho(S)$ 表示“实际内部边数占最大可能内部边数的比例”。

当 $\rho(S) = 1$ 时， S 构成团；当 $\rho(S)$ 较大但小于 1 时， S 对应密集子图。

因此，最大团问题可以看作密集子图问题的严格形式。后续实验可以先从最大团或人工植入团结构的测试图开始验证，再扩展到密集子图任务。

从建模角度看，最大团任务更适合用于验证算法的“约束保持能力”，因为每次加入节点都必须满足严格的两两相连条件；密集子图任务更适合用于验证算法的“结构发现能力”，因为它允许少量缺边，更接近真实网络中社区、功能模块或高关联节点群的形态。二者结合可以避免只在单一任务上证明算法有效。

3. 后续实验要验证的核心假设

本项目后续实验不应只是“实现一个算法并运行”，而应围绕明确假设展开。这里提出三个核心假设。

3.1 假设一：CTQW 概率能够反映图的全局结构

传统贪心算法通常依赖节点度数：

$$Score(v) = deg(v)$$

或者候选节点与当前集合 S 的连接数量：

$$Score(v, S) = |\{u \in S : (u, v) \in E\}|$$


这些指标主要反映局部结构，无法充分表达图中远距离路径、多跳连接关系和整体拓扑特征。

连续时间量子游走的节点概率为：

$$P_v(t) = |\langle v | e^{-iHt} | \psi_0 \rangle|^2$$

其中， H 由图结构决定， $|\psi_0\rangle$ 为初始态， t 为演化时间。由于 e^{-iHt} 的计算涉及整个图结构，因此 $P_v(t)$ 不只是局部邻域信息，而是包含多路径传播和全局拓扑影响的结果。

连续时间量子游走如何形成全局概率信号



与经典随机游走不同，CTQW 演化的是概率幅而不是概率本身。概率幅可以在不同路径之间相干叠加，最终观测概率由幅度的模平方给出。因此，在图中存在多条相互支持的路径或紧密连接的子结构时，量子概率可能在这些区域形成更明显的集中；在路径相位相互抵消的位置，概率也可能被抑制。这种“增强与抵消并存”的干涉机制，是量子游走区别于单纯度数评分或经典扩散模型的重要来源。

后续实验应验证：

在含有团或密集子图的测试图中，目标区域节点的 CTQW 概率是否显著高于普通背景节点。

可采用如下指标：

$$Ratio = \frac{Mean(P_v, v \in S_{target})}{Mean(P_v, v \notin S_{target})}$$

若 $Ratio > 1$ ，说明目标区域节点平均概率高于非目标区域节点，CTQW 概率分布对目标结构具有一定识别能力。

3.2 假设二：量子概率评分能够改善贪心选择质量

如果 CTQW 概率确实能够突出目标结构，那么将其作为贪心评分函数应当能够提高节点选择质量。

传统贪心方法每轮选择局部得分最高的节点，而本项目算法每轮选择量子评分较高的节点：

$$v^* = \arg \max_{v \in C(S)} P_v(t)$$

其中， $C(S)$ 为满足约束的候选节点集合。

后续实验应验证：

在相同输入图和相同停止条件下，量子引导贪心算法得到的团大小、子图密度或目标函数值是否优于纯经典贪心算法。

对应实验指标包括：

- 最大团任务中的最终团大小 $|S|$ ；
- 密集子图任务中的最终密度 $\rho(S)$ ；
- 算法运行时间；
- 多次运行平均结果；
- 成功率或达到目标质量的比例。

3.3 假设三：混合评分比单一评分更稳定

单独使用量子概率可能受演化时间 t 、扰动强度 λ 和初态选择影响；单独使用经典评分又容易陷入局部最优。因此，本项目采用混合评分函数：

$$Score(v, S) = \alpha \tilde{Q}(v, S) + (1 - \alpha) \tilde{R}(v, S)$$

其中：

- $\tilde{Q}(v, S)$ 为归一化后的量子评分；
- $\tilde{R}(v, S)$ 为归一化后的经典评分；
- $\alpha \in [0, 1]$ 为量子信息权重。

当 $\alpha = 0$ 时，算法退化为纯经典贪心；当 $\alpha = 1$ 时，算法退化为纯量子概率评分；当 $0 < \alpha < 1$ 时，算法为量子—经典混合评分。

后续实验应验证：

当 α 在不同取值下变化时，算法性能是否存在稳定优于纯经典或纯量子评分的区间。

该实验可以直接支撑项目题目中的“量子游走与贪心策略结合”，证明算法不是简单替换评分函数，而是在全局概率信号与局部结构约束之间进行融合。

4. 连续时间量子游走模型

连续时间量子游走是经典随机游走的量子对应形式。经典随机游走描述的是概率分布在图上的扩散，而连续时间量子游走描述的是概率幅在图上的相干演化。

在图 $G = (V, E)$ 上，定义节点基态为：

$$|v\rangle, \quad v \in V$$

系统状态可表示为：

$$|\psi(t)\rangle = \sum_{v \in V} \alpha_v(t) |v\rangle$$

其中， $\alpha_v(t)$ 是节点 v 上的概率幅。节点 v 被观测到的概率为：

$$P_v(t) = |\alpha_v(t)|^2$$

CTQW 的演化由薛定谔方程给出：

$$i\hbar \frac{\partial}{\partial t} |\psi(t)\rangle = H |\psi(t)\rangle$$

令 $\hbar = 1$ ，则有：

$$i \frac{\partial}{\partial t} |\psi(t)\rangle = H |\psi(t)\rangle$$

其形式解为：

$$|\psi(t)\rangle = e^{-iHt}|\psi_0\rangle$$

其中：

$$U(t) = e^{-iHt}$$

为时间演化算子。

因此，节点 v 在时刻 t 的概率为：

$$P_v(t) = |\langle v|U(t)|\psi_0\rangle|^2 = |\langle v|e^{-iHt}|\psi_0\rangle|^2$$

在本项目中，CTQW 的主要作用不是直接给出最终解，而是生成一个节点概率分布。该概率分布随后被用于构造贪心算法的评分函数。

为了更清楚地看到这个概率分布如何由图结构产生，可以把状态写成列向量形式。若图中共有 $n = |V|$ 个节点，取节点基：

$$|1\rangle = (1, 0, \dots, 0)^T, \quad |2\rangle = (0, 1, \dots, 0)^T, \quad \dots, \quad |n\rangle = (0, 0, \dots, 1)^T$$

则量子态可写成：

$$|\psi(t)\rangle = (\alpha_1(t), \alpha_2(t), \dots, \alpha_n(t))^T$$

薛定谔方程对应为矩阵微分方程：

$$i \frac{d}{dt} \begin{pmatrix} \alpha_1(t) \\ \alpha_2(t) \\ \vdots \\ \alpha_n(t) \end{pmatrix} = H \begin{pmatrix} \alpha_1(t) \\ \alpha_2(t) \\ \vdots \\ \alpha_n(t) \end{pmatrix}$$

若 H 是 Hermitian 矩阵，则 $U(t) = e^{-iHt}$ 是幺正矩阵，即：

$$U^\dagger(t)U(t) = I$$

因此状态范数保持不变：

$$\langle \psi(t) | \psi(t) \rangle = \langle \psi_0 | U^\dagger(t) U(t) | \psi_0 \rangle = \langle \psi_0 | \psi_0 \rangle = 1$$

这说明所有节点概率之和始终为 1：

$$\sum_{v \in V} P_v(t) = \sum_{v \in V} |\alpha_v(t)|^2 = 1$$

所以 CTQW 输出的 $P_v(t)$ 可以被直接解释为一个合法的节点概率分布。

进一步地，矩阵指数可以展开为：

$$e^{-iHt} = I - iHt - \frac{H^2 t^2}{2!} + \frac{iH^3 t^3}{3!} + \dots$$

如果取 $H = A$ ，则 A^k 的元素 $(A^k)_{uv}$ 与图中从 u 到 v 的长度为 k 的路径数量有关。因此， e^{-iAt} 中不仅包含一步邻接关系，也包含多步路径信息。这就是 CTQW 概率能够反映全局拓扑结构的数学原因：它不是只看某个节点的度数，而是在演化过程中综合了不同长度路径对概率幅的贡献。

5. 哈密顿量设计：从“原图演化”到“候选解引导演化”

如果直接取：

$$H = A$$

则 CTQW 只反映原图结构，无法利用当前贪心算法已经选出的中间解。为了让量子演化与当前搜索状态相关，本项目引入种子集合扰动项。

设当前已经选中的节点集合为：

$$S \subseteq V$$

称为种子集合。构造改进哈密顿量：

$$H = A + \lambda \sum_{u \in S} |u\rangle\langle u|$$

其中：

- A 为图邻接矩阵；
- S 为当前种子集合；
- $|u\rangle\langle u|$ 为节点 u 的投影算子；
- λ 为扰动强度。

该式的作用是：在当前种子节点位置加入额外权重，使量子游走不仅受原图结构影响，也受当前候选解状态影响。

从矩阵形式看，投影算子 $|u\rangle\langle u|$ 是一个只有第 u 个对角元为 1、其余元素为 0 的矩阵。例如当 $n = 4$ 且 $u = 2$ 时：

$$|2\rangle\langle 2| = \begin{pmatrix} 0 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \end{pmatrix}$$

因此：

$$\lambda \sum_{u \in S} |u\rangle\langle u|$$

等价于在哈密顿量的种子节点对角位置加入额外势能项。若把 A 看作节点之间的“跃迁耦合”，那么该对角扰动可以看作对当前已选节点施加一个与搜索状态有关的局域势。这样，演化不再只由静态图结构决定，而会随着 S 的变化而变化。

这一点对贪心算法很重要。普通 CTQW 使用固定的 $H = A$ ，每一轮得到的全局概率分布相同；而加入 S 相关扰动后，第 r 轮的哈密顿量为：

$$H^{(r)} = A + \lambda \sum_{u \in S^{(r)}} |u\rangle\langle u|$$

因此概率分布也变为：

$$P_v^{(r)}(t) = |\langle v | e^{-iH^{(r)}t} | \psi_0^{(r)} \rangle|^2$$

这使得算法每一步的量子评分都与当前部分解 $S^{(r)}$ 绑定，而不是一次性生成固定排名。

从实验角度看， λ 是一个重要参数。后续实验不应固定只测一个值，而应比较不同 λ 下算法性能：

$$\lambda \in \{0, 0.1, 0.5, 1, 2, 5\}$$

其中：

- $\lambda = 0$ 表示无种子扰动；
- $\lambda > 0$ 表示引入当前解引导。

这样可以验证：

■ 种子扰动项是否真的提升了算法性能。

如果 $\lambda = 0$ 的实验组明显弱于 $\lambda > 0$ 的实验组，则说明当前解状态嵌入哈密顿量是有效的；如果差异不明显，则说明该扰动机制需要进一步调整。

需要注意的是，扰动项并不是为了强行把概率固定在已选节点上，而是为了让演化算子感知当前搜索状态。 λ 过小，算法近似退化为只看原图结构； λ 过大，概率可能过度集中在种子附近，降低对远处候选区域的探索能力。因此， λ 的合理区间应通过实验确定，而不能只凭理论预设。

6. 初始态设计

初始态决定量子游走从哪里出发。为了与当前贪心状态结合，本项目采用基于种子集合的均匀初态：

$$|\psi_0\rangle = \frac{1}{\sqrt{|S|}} \sum_{u \in S} |u\rangle$$

含义是：量子态从当前已选节点集合均匀出发，向图中其他区域传播。

这里的系数 $\frac{1}{\sqrt{|S|}}$ 用来保证初始态归一化。因为不同节点基态正交，即：

$$\langle u|v\rangle = \begin{cases} 1, & u = v \\ 0, & u \neq v \end{cases}$$

所以：

$$\langle \psi_0|\psi_0\rangle = \frac{1}{|S|} \sum_{u \in S} \sum_{v \in S} \langle u|v\rangle = \frac{1}{|S|} \sum_{u \in S} 1 = 1$$

这说明初始时总概率为 1，并且每个种子节点的初始概率均为 $\frac{1}{|S|}$ 。

当 S 为空时，有两种可选初始化方式。

6.1 均匀初态

$$|\psi_0\rangle = \frac{1}{\sqrt{|V|}} \sum_{v \in V} |v\rangle$$

优点是没有先验偏置，能够从全图整体出发；缺点是对目标结构的引导较弱，尤其在图规模较大或噪声边较多时，概率分布可能较为分散。

6.2 经典启发式初始化

选择度数最高节点作为初始种子：

$$s_0 = \arg \max_{v \in V} \deg(v)$$

然后令：

$$S = \{s_0\}$$

这种方式更适合最大团和密集子图任务，因为高质量解通常需要从具有较强连接能力的节点附近开始。

后续实验可以将以下初始化方式作为对照：

1. 均匀初态；
2. 最高度节点初始化；
3. 随机节点初始化。

这样可以验证算法是否对初始条件过于敏感。

7. 候选集合约束

量子概率不能直接决定最终选择，因为图组合优化问题本身有约束。为了避免选出不满足问题条件的节点，需要先构造候选集合。

7.1 最大团任务候选集合

对于最大团问题，候选节点必须与当前集合 S 中所有节点相连：

$$C(S) = \{v \in V \setminus S \mid \forall u \in S, (u, v) \in E\}$$

每一轮只能从 $C(S)$ 中选择节点。这样可以保证算法输出结果始终是一个合法团。

其正确性可以用归纳法说明。初始时若 S 为空或只包含一个节点，则 S 显然是团。假设第 r 轮开始时 $S^{(r)}$ 是团，并从候选集合中选择 $v \in C(S^{(r)})$ 。根据候选集合定义， v 与 $S^{(r)}$ 中每个节点都相连；而 $S^{(r)}$ 内部节点两两相连。因此：

$$S^{(r+1)} = S^{(r)} \cup \{v\}$$

仍然满足任意两个节点之间都有边，所以仍是团。由归纳法可知，只要每轮都从 $C(S)$ 中选点，算法输出的集合始终是合法团。

如果某一轮出现：

$$C(S) = \emptyset$$

则说明当前团无法继续扩展，算法停止。

7.2 密集子图任务候选集合

对于密集子图问题，不要求候选节点与 S 中所有节点相连，只要求加入后密度不低于阈值：

$$C(S) = \{v \in V \setminus S \mid \rho(S \cup \{v\}) \geq \theta\}$$

其中， θ 是密度阈值。

如果目标是寻找规模为 k 的密集子图，也可以不设置硬阈值，而是让算法一直迭代到：

$$|S| = k$$

再比较最终密度 $\rho(S)$ 。

8. 评分函数设计

为了服务后续实验，本项目设计三类评分函数，分别用于对照实验和消融实验。

8.1 经典贪心评分

经典评分只考虑候选节点与当前集合的连接关系：

$$R(v, S) = \frac{|\{u \in S : (u, v) \in E\}|}{|S|}$$

对于最大团任务，合法候选节点满足 $R(v, S) = 1$ ，此时可以进一步使用候选节点在剩余候选图中的度数：

$$R_{clique}(v, S) = \deg_{C(S)}(v)$$

其中, $\text{deg}_{C(S)}(v)$ 表示节点 v 在候选集合诱导子图中的度数。

该指标可以衡量: 如果选择节点 v , 后续还有多少节点可能继续加入当前团。

这里使用 $\text{deg}_{C(S)}(v)$ 的原因是, 最大团任务中所有合法候选节点都已经满足:

$$\forall u \in S, (u, v) \in E$$

因此仅用 $R(v, S)$ 时, 所有候选节点都得到相同分数:

$$R(v, S) = 1$$

这会导致贪心算法无法区分候选节点的优劣。引入 $\text{deg}_{C(S)}(v)$ 后, 评分关注的是候选节点在剩余可扩展区域中的连接能力。若选择某个 v 后仍有许多候选节点与它相连, 则当前团更可能继续扩展; 反之, 若 v 在候选子图中几乎孤立, 则选择它可能过早终止搜索。

对于密集子图任务, 经典评分可以使用加入节点后的密度增量:

$$\Delta\rho(v, S) = \rho(S \cup \{v\}) - \rho(S)$$

或者使用候选节点与当前集合的连接比例:

$$R_{dense}(v, S) = \frac{|\{u \in S: (u, v) \in E\}|}{|S|}$$

前者更直接对应目标函数, 后者计算更简单, 适合在大规模图上快速筛选候选节点。

8.2 量子概率评分

量子评分定义为:

$$Q(v, S) = P_v(t) = |\langle v | e^{-iHt} | \psi_0 \rangle|^2$$

选择规则为:

$$v^* = \arg \max_{v \in C(S)} Q(v, S)$$

这对应纯量子引导版本。

该版本可以用于验证: 不加入经典评分时, CTQW 概率本身是否具备有效的节点选择能力。

在实际实现中，量子概率评分通常只在候选集合上比较，而不是在所有节点上比较。也就是说，虽然 CTQW 会给每个节点一个概率 $P_v(t)$ ，但真正参与选择的是：

$$Q_C(v, S) = P_v(t), \quad v \in C(S)$$

这样做的原因是：量子演化本身不知道最大团或密集子图的具体约束，它只负责给出结构相关的全局信号。如果直接在全体节点上取最大概率，可能选到一个概率较高但不满足组合优化约束的节点。因此，候选集合相当于先做“可行性投影”，再让量子评分参与排序。

8.3 混合评分

为了兼顾量子全局信息与经典局部约束，本项目采用混合评分：

$$Score(v, S) = \alpha \tilde{Q}(v, S) + (1 - \alpha) \tilde{R}(v, S)$$

其中：

- $\tilde{Q}(v, S)$ 为归一化后的量子评分；
- $\tilde{R}(v, S)$ 为归一化后的经典评分；
- $\alpha \in [0, 1]$ 为量子信息权重。

归一化方式可采用 min-max 归一化：

$$\tilde{Q}(v, S) = \frac{Q(v, S) - Q_{min}}{Q_{max} - Q_{min} + \varepsilon}$$

$$\tilde{R}(v, S) = \frac{R(v, S) - R_{min}}{R_{max} - R_{min} + \varepsilon}$$

其中， ε 是防止分母为零的小常数。

归一化是必要的，因为 Q 和 R 的数值尺度通常不同。量子概率满足：

$$0 \leq Q(v, S) \leq 1, \quad \sum_{v \in V} Q(v, S) = 1$$

而经典评分可能是整数度数，也可能是密度增量。例如在最大团任务中， $R_{clique}(v, S)$ 可能取 $0, 1, 2, \dots$ 。如果不归一化，混合评分中的较大数值尺度会主导结果，使 α 失去清晰含义。

归一化时， Q_{min} 、 Q_{max} 、 R_{min} 、 R_{max} 应只在当前候选集合 $C(S)$ 上计算：

$$Q_{min} = \min_{v \in C(S)} Q(v, S), \quad Q_{max} = \max_{v \in C(S)} Q(v, S)$$

$$R_{min} = \min_{v \in C(S)} R(v, S), \quad R_{max} = \max_{v \in C(S)} R(v, S)$$

这样可以保证本轮评分只比较当前真正可选的节点，而不会被不可行节点的极端值影响。


后续实验中可以设置：

$$\alpha \in \{0, 0.25, 0.5, 0.75, 1\}$$

对应：

- $\alpha = 0$ ：纯经典贪心；
- $\alpha = 1$ ：纯量子概率；
- $0 < \alpha < 1$ ：量子—经典混合评分。

这个设计能够直接支持消融实验和参数敏感性分析。




该评分框架体现了本项目的核心思想：先由候选集合保证“选出来的节点合法”，再由混合评分决定“合法节点中哪个更值得选”。其中， Q 提供由 CTQW 产生的全局拓扑信号， R 提供与当前解直接相关的局部结构信号， α 控制二者的权衡。这样设计的好处是，即使量子概率在某些图上存在波动，经典约束和经典评分仍能提供稳定的下界；而当量子概率确实捕捉到目标结构时，混合评分又能把这种优势转化为具体选择。

9. 一轮决策示例

为了说明算法每一轮如何从公式落到具体选择，下面给出一个小规模示例。设图中有 7 个节点：

$$V = \{1, 2, 3, 4, 5, 6, 7\}$$

一轮量子引导贪心决策示例



其中 $\{1, 2, 3, 4\}$ 是一个较密集区域。设边集为：

$$E = \{(1, 2), (1, 3), (1, 4), (1, 5), (2, 3), (2, 4), (2, 5), (3, 4), (3, 5), (4, 6), (5, 7)\}$$

可以看到，节点 1、2、3、4 之间所需的六条边 $(1, 2), (1, 3), (1, 4), (2, 3), (2, 4), (3, 4)$ 都存在，因此 $\{1, 2, 3, 4\}$ 构成一个 4 阶团。现在假设算法已经选中：

$$S = \{1, 2\}$$

在最大团任务中，候选节点必须同时与 1 和 2 相连，即：

$$C(S) = \{v \in V \setminus S \mid (1, v) \in E, (2, v) \in E\}$$

逐个检查 $V \setminus S = \{3, 4, 5, 6, 7\}$ ：

- 节点 3: $(1, 3) \in E$ 且 $(2, 3) \in E$ ，所以 $3 \in C(S)$ ；
- 节点 4: $(1, 4) \in E$ 且 $(2, 4) \in E$ ，所以 $4 \in C(S)$ ；
- 节点 5: $(1, 5) \in E$ 且 $(2, 5) \in E$ ，所以 $5 \in C(S)$ ；
- 节点 6: 不存在 $(1, 6)$ 或 $(2, 6)$ ，所以 $6 \notin C(S)$ ；
- 节点 7: 不存在 $(1, 7)$ 或 $(2, 7)$ ，所以 $7 \notin C(S)$ 。

因此本轮候选集合为：

$$C(S) = \{3, 4, 5\}$$

随后构造哈密顿量：

$$H = A + \lambda(|1\rangle\langle 1| + |2\rangle\langle 2|)$$

并令初始态为：

$$|\psi_0\rangle = \frac{1}{\sqrt{2}}(|1\rangle + |2\rangle)$$

为了让计算过程清晰，设取 $\lambda = 1$ ，演化时间为 $t = 1$ 。真实实验中会由矩阵指数：

$$|\psi(t)\rangle = e^{-iHt}|\psi_0\rangle$$

计算出所有节点概率。这里假设本轮 CTQW 计算得到的候选节点概率为：

$$Q(3, S) = 0.31, \quad Q(4, S) = 0.24, \quad Q(5, S) = 0.18$$

这些数值只用于展示一轮决策如何进行；实际实验中应由代码直接计算得到。

接着计算经典评分。由于当前任务是最大团，候选节点都已经与 S 中所有节点相连，所以简单连接比例均为 1，无法区分节点优劣。因此使用候选子图度数：

$$R_{clique}(v, S) = \deg_{C(S)}(v)$$

候选集合诱导子图只包含节点 $\{3, 4, 5\}$ 。根据边集可知：

- 节点 3 与 4、5 都相连，所以 $R(3, S) = 2$ ；
- 节点 4 只与 3 相连，所以 $R(4, S) = 1$ ；
- 节点 5 只与 3 相连，所以 $R(5, S) = 1$ 。

因此：

$$R(3, S) = 2, \quad R(4, S) = 1, \quad R(5, S) = 1$$

然后对 Q 和 R 分别做 min-max 归一化。对量子评分，有：

$$Q_{max} = 0.31, \quad Q_{min} = 0.18$$

所以：

$$\tilde{Q}(3, S) = \frac{0.31-0.18}{0.31-0.18} = 1$$

$$\tilde{Q}(4, S) = \frac{0.24-0.18}{0.31-0.18} \approx 0.46$$

$$\tilde{Q}(5, S) = \frac{0.18-0.18}{0.31-0.18} = 0$$

对经典评分，有：

$$R_{max} = 2, \quad R_{min} = 1$$

所以：

$$\tilde{R}(3, S) = \frac{2-1}{2-1} = 1$$

$$\tilde{R}(4, S) = \frac{1-1}{2-1} = 0$$

$$\tilde{R}(5, S) = \frac{1-1}{2-1} = 0$$

取混合权重 $\alpha = 0.5$ ，则：

$$Score(v, S) = 0.5\tilde{Q}(v, S) + 0.5\tilde{R}(v, S)$$

逐项计算得到：

$$Score(3, S) = 0.5 \times 1 + 0.5 \times 1 = 1$$

$$Score(4, S) = 0.5 \times 0.46 + 0.5 \times 0 = 0.23$$

$$Score(5, S) = 0.5 \times 0 + 0.5 \times 0 = 0$$

汇总如下：

候选节点 v	量子概率 $Q(v, S)$	候选子图度数 $R(v, S)$	归一化后混合评分 $Score(v, S)$, $\alpha = 0.5$
3	0.31	2	1.00
4	0.24	1	0.23
5	0.18	1	0.00

因此本轮选择：

$$v^* = 3$$

并更新：

$$S \leftarrow \{1, 2, 3\}$$

更新后，下一轮候选集合变为：

$$C(\{1, 2, 3\}) = \{v \in V \setminus \{1, 2, 3\} \mid (1, v), (2, v), (3, v) \in E\}$$

由边集可知，节点 4 与 1、2、3 都相连，节点 5 与 1、2、3 也都相连，因此：

$$C(\{1, 2, 3\}) = \{4, 5\}$$

下一轮算法会基于新的 S 重新构造：

$$H = A + \lambda(|1\rangle\langle 1| + |2\rangle\langle 2| + |3\rangle\langle 3|)$$

并重新计算 CTQW 概率和混合评分。

这个例子展示了四点：第一，候选集合先排除不合法节点，保证最大团约束不被破坏；第二，量子评分 Q 用来反映节点与当前种子集合及整体图结构之间的传播关系；第三，经典评分 R 用来避免只凭概率选择后续扩展性较差的节点；第四，每次更新 S 后，哈密顿量、初始态、候选集合和评分都会随之改变，因此算法是一个动态迭代过程，而不是对节点做一次静态排序。

10. 数值实现与复杂度分析

在实验实现中，CTQW 的关键计算是矩阵指数：

$$U(t) = e^{-iHt}$$

若直接对 $n \times n$ 哈密顿量进行完整矩阵指数计算，时间复杂度通常约为 $O(n^3)$ ，空间复杂度约为 $O(n^2)$ 。因此，该方法更适合先在小规模或中等规模图上验证理论假设。

常见数值实现方式包括：

1. 直接使用矩阵指数函数，例如 `scipy.linalg.expm`；

2. 对 Hermitian 矩阵 H 做特征分解：

$$H = V\Lambda V^\dagger$$

则：

$$e^{-iHt} = Ve^{-i\Lambda t}V^\dagger$$

3. 对稀疏大图使用 Krylov 子空间方法近似计算 $e^{-iHt}|\psi_0\rangle$ ，避免显式构造完整的 $U(t)$ 。

对于本项目的课程实验，推荐先采用完整矩阵指数或特征分解实现，保证公式与代码直观一致；当图规模扩大后，再考虑稀疏近似方法。这样可以把实验分成两个层次：第一阶段验证量子概率评分是否有效，第二阶段再讨论算法可扩展性。

从整体算法看，每一轮贪心选择都需要重新构造候选集合、更新哈密顿量并计算 CTQW 概率。若迭代轮数为 m ，单轮 CTQW 计算代价为 T_{CTQW} ，候选评分代价为 T_{score} ，则总时间可粗略写为：

$$T_{total} = O(m(T_{CTQW} + T_{score}))$$

其中 T_{CTQW} 是主要瓶颈。因此，后续实验报告中除了比较解质量，也应记录运行时间，避免只强调量子评分带来的效果而忽略计算代价。

11. 方法边界与可能风险

本方法属于量子启发式算法设计，并不意味着在当前实验环境中真正调用量子硬件。实验中的 CTQW 通常由经典计算机模拟，因此算法优势主要体现在“量子动力学机制启发了新的评分函数”，而不是直接体现量子硬件加速。

更准确地说，本项目讨论的是“量子启发式经典算法”：量子游走提供了构造评分函数的物理和数学灵感，但实际实验依然在经典计算机上用矩阵运算模拟完成。因此，报告中不应表述为“算法获得了量子硬件加速”，而应表述为“算法利用 CTQW 的相干传播和干涉特征构造了区别于传统局部指标的全局拓扑评分”。这样既能体现项目的量子信息理论背景，也能避免把模型创新误写成硬件层面的速度优势。

需要在报告中说明以下边界：

- CTQW 概率分布对 t 、 λ 和初始态较敏感，单一参数下的好结果不能直接证明算法普遍有效；
- 对小图有效不代表对大图一定可扩展，因为矩阵指数计算可能成为主要瓶颈；
- 量子概率高不等于节点一定属于最优解，因此必须保留候选集合约束和经典评分；
- 若目标结构本身不明显，或背景图噪声过强，CTQW 概率可能无法稳定突出目标区域；
- 实验应采用多组随机图和多次重复运行，报告均值、方差和成功率，而不是只展示单次最优结果。

这些边界不会削弱项目价值，反而能使实验论证更加严谨：本项目要证明的是“CTQW 概率作为图组合优化启发式信号是否有用”，而不是声称它在所有图上都严格优于经典算法。

12. 算法流程

本项目提出的量子引导贪心算法如下。

Algorithm: Quantum-guided Greedy Algorithm

Input:

Graph $G=(V,E)$
Adjacency matrix A
Target size k or stopping condition
Evolution time t
Perturbation strength λ
Balance parameter α

Output:

Selected node set S

1. Initialize seed set S
2. while stopping condition is not satisfied do
3. Construct candidate set $C(S)$
4. if $C(S)$ is empty then
5. break
6. end if
7. Construct Hamiltonian:

$$H = A + \lambda \sum_{u \in S} |u\rangle\langle u|$$
8. Construct initial state:

$$|\psi_0\rangle = 1/\sqrt{|S|} \sum_{u \in S} |u\rangle$$
9. Perform CTQW evolution:

$$|\psi(t)\rangle = \exp(-iHt)|\psi_0\rangle$$
10. For each candidate node $v \in C(S)$, compute:

$$Q(v,S) = |\langle v|\psi(t)\rangle|^2$$
11. Compute classical score:

$$R(v,S)$$

```
12.    Normalize  $Q(v,S)$  and  $R(v,S)$ 

13.    Compute final score:
         $Score(v,S)=\alpha Q\_norm(v,S)+(1-\alpha)R\_norm(v,S)$ 

14.    select:
         $v^* = \operatorname{argmax} Score(v,S)$ 

15.    Update:
         $S = S \cup \{v^*\}$ 

16. end while

17. return  $S$ 
```

该流程明确了后续代码实现所需的候选集合、评分函数、参数和停止条件，可以直接作为实验实现的算法依据。

13. 后续实验设计依据

本部分理论设计直接对应后续实验。建议实验部分围绕以下四组实验展开。

13.1 实验设置总表

为保证实验具有可复现性，建议先使用人工生成图进行验证，再扩展到真实网络数据。人工图的优势是目标结构已知，可以直接判断 CTQW 概率是否突出 **planted clique** 或 **planted dense subgraph**。

实验因素	建议取值	作用
图规模 n	30, 50, 100	观察算法随规模变化的表现
背景边概率 p	0.1, 0.2, 0.3	控制噪声边密度
植入团大小 k	5, 8, 10	控制目标结构强度
密集子图密度 ρ	0.6, 0.7, 0.8	用于非严格团任务
演化时间 t	0.5, 1, 2, 5, 10	测试 CTQW 动力学敏感性
扰动强度 λ	0, 0.1, 0.5, 1, 2, 5	测试种子扰动作用
混合权重 α	0, 0.25, 0.5, 0.75, 1	比较经典、量子和混合评分

实验因素	建议取值	作用
重复次数	每组至少 20 次	统计均值、方差和成功率

每组实验应固定随机种子列表，并记录输入图、最终节点集合、目标函数值和运行时间。这样即使不同算法出现接近结果，也可以进一步比较稳定性和计算代价。

13.2 实验一：CTQW 概率分布可视化

目的：

验证 CTQW 是否能够在团或密集子图附近形成概率集中。

实验方法：

- 1. 构造含 planted clique 的测试图；
- 2. 运行 CTQW；
- 3. 记录每个节点的 $P_v(t)$ ；
- 4. 比较团内节点与团外节点的平均概率。

评价指标：

$$Ratio = \frac{Mean(P_v, v \in S_{target})}{Mean(P_v, v \notin S_{target})}$$

若 $Ratio > 1$ ，说明目标区域概率更高。

可视化方式：

- 节点大小表示 $P_v(t)$ ；
- 节点颜色深浅表示量子概率；
- 高亮真实 planted clique 区域；
- 对比经典度数分布与 CTQW 概率分布。

13.3 实验二：与经典贪心算法对比

目的：

验证量子引导评分是否提升求解质量。

对照方法：

- 1. 纯度数贪心；
- 2. 候选子图度数贪心；
- 3. 模拟退火；
- 4. 纯量子概率贪心；
- 5. 量子—经典混合贪心。

评价指标：

- 最大团任务：找到的团大小 $|S|$ ；
- 密集子图任务：最终密度 $\rho(S)$ ；
- 运行时间；
- 成功率；
- 平均目标函数值。

该实验用于回答：

量子引导贪心算法是否真正优于传统经典启发式方法？

13.4 实验三：消融实验

目的：

验证每个模块是否真的有贡献。

消融设置：

实验组	量子概率 Q	经典评分 R	种子扰动 λ	目的
A	否	是	否	纯经典基线
B	是	否	否	验证原始 CTQW 概率
C	是	否	是	验证种子扰动作用
D	是	是	是	完整算法

如果 D 组表现最好，说明“量子概率 + 种子扰动 + 经典约束”三者结合是有效的。

13.5 实验四：参数敏感性分析

目的：

验证算法是否稳定。

参数包括：

$t \in 0.5, 1, 2, 5, 10$


$\lambda \in 0, 0.1, 0.5, 1, 2, 5$

$\alpha \in 0, 0.25, 0.5, 0.75, 1$

观察指标：

- 最终解质量；
- 运行时间；
- 波动范围；
- 最优参数区间。

这部分适合用热力图展示。例如，可以固定 α ，观察 t 与 λ 对解质量的共同影响；也可以固定 t 和 λ ，观察 α 对最终解质量的影响。



预期上， $\alpha = 0$ 对应纯经典贪心，结果较稳定但可能陷入局部最优； $\alpha = 1$ 对应纯量子概率，可能捕捉全局结构但对参数更敏感；中间区域若表现最好，则说明量子全局信号与经典局部约束之间确实存在互补关系。需要强调的是，该图只是实验现象的预期示意，最终结论必须以真实实验结果为准。

参考文献

[1] E. Farhi and S. Gutmann, "Quantum Computation and Decision Trees," *Physical Review A*, vol. 58, no. 2, pp. 915-928, 1998.

用途：支撑连续时间量子动力学可用于算法设计。

[2] A. M. Childs, E. Farhi, and S. Gutmann, "An Example of the Difference Between Quantum and Classical Random Walks," *Quantum Information Processing*, vol. 1, pp. 35-43, 2002.

用途：支撑量子游走与经典随机游走在图上传播行为不同。

[3] J. Kempe, "Quantum Random Walks: An Introductory Overview," *Contemporary Physics*, vol. 44, no. 4, pp. 307-327, 2003.

用途：支撑量子游走基础理论和算法意义。

[4] S. E. Venegas-Andraca, "Quantum Walks: A Comprehensive Review," *Quantum Information Processing*, vol. 11, pp. 1015-1106, 2012.

用途：支撑连续时间和离散时间量子游走的系统综述。

[5] A. M. Childs, "Universal Computation by Quantum Walk," *Physical Review Letters*, vol. 102, article 180501, 2009.

用途：说明量子游走在量子计算理论中的重要性。

[6] S. Kirkpatrick, C. D. Gelatt, and M. P. Vecchi, "Optimization by Simulated Annealing," *Science*, vol. 220, no. 4598, pp. 671-680, 1983.

用途：作为经典启发式优化方法的对照文献。

[7] P. M. Pardalos and J. Xue, "The Maximum Clique Problem," *Journal of Global Optimization*, vol. 4, pp. 301-328, 1994.

用途：支撑最大团问题的复杂性、算法背景和应用价值。

[8] U. Feige, D. Kortsarz, and D. Peleg, "The Dense k-Subgraph Problem," *Algorithmica*, vol. 29, pp. 410-421, 2001.

用途：支撑密集子图问题背景。